# Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks

Taesung Park, UC Berkeley

2019. 05 30


Boaz 분석 D조


문현주 신광욱 고동희 박서호

https://arxiv.org/pdf/1703.10593.pdf

# Index


- 1. Abstract & Introduction
- 2. Related Work
- 3. Formulation
- 4. Implementation
- 5. Results
- 6. Limitations & Discussion








즉, cyclegan 은 한 이미지를 다른 dataset의 이미지로 바꿔줄 수 있는 기능을 하게 된다.




그와 동시에 반대쪽 수정 작업도 동시에 훈련시킬 수 있다.

# How does it work?



pix2pix (Isola et al., 2017) - Input 과 Output이 모두 사진이어야 한다.



- Supervised
- loss: Minimize the difference between output *G(x)* and ground truth *y*


Data from [Tylecek, 2013]

X= 각 픽셀 별로 라벨을 표시한 dataset Y= 건물 앞 부분 찍은 dataset.

# pix2pix (Isola et al., 2017)

Loss: Minimize the difference between output G(x) and the ground truth y

$$\sum_{(x,y)} \|y - G(x)\|_1$$



Input



Output



Ground Truth

### pix2pix (Isola et al., 2017)

Loss: Minimize the difference between output G(x) and the ground truth y

$$\sum_{(x,y)} \|y - G(x)\|_1$$








Output



Ground Truth

Let another deep network point out the difference

Generative Adversarial Network (GAN) (Goodfellow et al., 2014)




D: 뭐가 진짜고 뭐가 가짜인지 판별해내는 역할

G: D가 진짜/가짜 구별을 하기 어려울 정도로 Realistic한 이미지 생성하는 역할

### Pix2pix (P. Isola et al., 2017)

Loss: Minimize the difference between and output G(x) and ground truth y

$$\sum_{(x,y)} ||y - G(x)||_1 + L_{GAN}(G(x), y)$$



Input



Ground Truth



L1 loss only



L1+GAN loss


#### Related Work [Pix2Pix] 요약:

- 1. Image to Image Mapping Network에서 Photo-realistic을 추구하고 싶음
- -> 그래서 GAN의 Adversarial Training을 도입
- 3. U-Net과 PatchGAN등을 통해서 성능 최적화
- 4. Training Data가 Pair로 존재해야 함 (그래서 CycleGAN, DiscoGAN이 나

#### 실습코드:


https://github.com/tensorflow/tensorflow/blob/r1.13/tensorflow/contrib/eager/python/examples/pix2pix/pix2pix\_eager.ipynb

**CycleGAN** (Zhu et al. 2017) → '쌍을 이루는'(Paired) 데이터가 아닌, '쌍을 이루지 않 는'(Unpaired) 데이터로 학습.




Pix2Pix에서나 CycleGAN의 공통된 문제 정의: '한 도메인에 있는 이미지를 다른 도메인으로 해석한다.' 그러나 Pix2Pix 모델에서는 이 문제를 풀기 위해서는 반드시 두 도메인 양쪽에 대응되는 데이터 쌍이 존재해야 한다. CycleGAN 모델에서 제시하는 것은, *그러한 데이터 쌍이 없이도* 문제를 풀어보자는 것


Loss:  $L_{GAN}(G(x), y)$  G(x) should just look photorealistic and be able to reconstruct x




Loss

 $L_{GAN}(G(x), y) + \|F(G(x)) - x\|_1$  G(x) should just look photorealistic and F(G(x)) should be F(G(x)) = x, where F is the inverse deep network






$$L_{GAN}(G(x), y) + ||F(G(x)) - x||_1$$



$$L_{GAN}(F(y),x) + \|G(F(y)) - y\|_{1}$$



→ 4가지의 Loss term이 합쳐진것이 Cycle Gan 의 Full Loss Formulation:

$$L_{GAN}(G(x), y) + ||F(G(x)) - x||_1 + L_{GAN}(F(y), x) + ||G(F(y)) - y||_1$$







Figure 3: (a) Our model contains two mapping functions  $G: X \to Y$  and  $F: Y \to X$ , and associated adversarial discriminators  $D_Y$  and  $D_X$ .  $D_Y$  encourages G to translate X into outputs indistinguishable from domain Y, and vice versa for  $D_X$  and F. To further regularize the mappings, we introduce two *cycle consistency losses* that capture the intuition that if we translate from one domain to the other and back again we should arrive at where we started: (b) forward cycle-consistency loss:  $x \to G(x) \to F(G(x)) \approx x$ , and (c) backward cycle-consistency loss:  $y \to F(y) \to G(F(y)) \approx y$ 





#### Network Architecture – Generator *G*



처음 시도했던 Architecture


encoder-decode에 skip-connection을 추가적으로 사용한 U-Net을 이용

skip-connection을 이용함으로써 Bottle-neck을 통과하면서 생기는 컨텐츠의 손실을 방지

하지만 depth가 거의 없어서 결과가 만족스럽지 않음

#### Network Architecture – Generator *G*

#### ResNet [He et al.] [Johnson et al.]



최종적으로 사용한 Architecture


Bottle-neck이 없으므로 컨텐츠 디테일에 손실이 적음

ResNet의 특징인 residual block이 skip-connection

이미지 퀄리티 측면에서는 만족할 만한 결과

하지만 bottle-neck이 없어서 메모리를 많이 차지 그 결과, 학습할 수 있는 parameter의 수가 적어져 형태변화에 제한이 생기는 것 같음


### DiscoGAN과의 차이점 – Generator **G**



Bottle-neck에서 콘텐츠의 디테일에 손실이 크지만, 보다 자유로운 변화된 이미지 생성이 가능

목적의 차이가 존재 CycleGAN의 경우 '컴퓨터 그래픽을 사진처럼 바꿔보자', '고해상도의 이미지를 다루어 보자'라는 목적으로 시작

#### Network Architecture – Discriminator **D**



Discriminator에서 사용한 Architecture는 PatchGAN이다.


전체 이미지에 대해서 진짜/가짜를 구별 – ImageGAN 특정 크기의 patch 단위에 대하여 진짜/가짜 구별 – PatchGAN

### Training details - Loss

GANs with cross-entropy loss

$$\mathcal{L}_{GAN}(G, D_Y, X, Y) = \mathbb{E}_{y \sim p_{\text{data}}(y)} [\log D_Y(y)] + \mathbb{E}_{x \sim p_{\text{data}}(x)} [\log (1 - D_Y(G(x)))]$$

원래 GAN의 Loss는 Vanishing gradients로 인해서 학습과 정에 어려움이 생김




Vanishing gradients

### Training details - Loss


Least square GANs [Mao et al. 2016]
Stable training + better results

$$\mathcal{L}_{LSGAN}(G, D_Y, X, Y) = \mathbb{E}_{y \sim p_{data}(y)} [(D_Y(y) - 1)^2] + \mathbb{E}_{x \sim p_{data}(x)} [D_Y(G(x))^2],$$

여러가지 다른 형태의 loss를 가진 GAN들이 있었으나, 휴리스틱하게 선택



### Training details – replay buffer




불안정성을 해결하기 위해서 두가지 솔루션

1> D를 여러 개 생성하여 평균하여 결과 제시, 메모리 소모가 커지는 단점

2> 이전에 G가 생성했던 이미지를 D에게 주기적으로 제시 -> 예전 G가 어떻게 행동했는지 D가 대응하면서 보다 안정정으로 학습이 진행


### Evaluation Metrics – AMT perceptual studies



### Evaluation Metrics – AMT perceptual studies

	$\mathbf{Map} \to \mathbf{Photo}$	$\mathbf{Photo} \to \mathbf{Map}$
Loss	% Turkers labeled real	% Turkers labeled real
CoGAN [32]	$0.6\% \pm 0.5\%$	$0.9\% \pm 0.5\%$
BiGAN/ALI [9, 7]	$2.1\% \pm 1.0\%$	$1.9\% \pm 0.9\%$
SimGAN [46]	$0.7\% \pm 0.5\%$	$2.6\% \pm 1.1\%$
Feature loss + GAN	$1.2\%\pm0.6\%$	$0.3\% \pm 0.2\%$
CycleGAN (ours)	$26.8\%\pm2.8\%$	$23.2\% \pm 3.4\%$

### Evaluation Metrics – FCN score / Semantic segmentation metrics




### Evaluation Metrics – FCN score / Semantic segmentation metrics

Loss	Per-pixel acc.	Per-class acc.	Class IOU
CoGAN [32]	0.40	0.10	0.06
BiGAN/ALI [9, 7]	0.19	0.06	0.02
SimGAN [46]	0.20	0.10	0.04
Feature loss + GAN	0.06	0.04	0.01
CycleGAN (ours)	0.52	0.17	0.11
pix2pix [22]	0.71	0.25	0.18

더 여러가지 결과가 제시 되어있지만, 간단하게 말하면 pix2pix보다는 성능이 좋지 않지만 다른 baseline들 보다는 성능이 많이 좋다.

### Analysis of the loss function



## Application on Domain Adaptation



GTA5 CG Input Output

### Application on Domain Adaptation




Train on CycleGAN data



Test on real images

	Per-class accuracy	Per-pixel accuracy
Oracle (Train and test on Real)	60.3	93.1
Train on CG, test on Real	17.9	54.0
FCN in the wild [Hoffman et al.]	27.1 (+6.0)	*
Train on CycleGAN, test on Real	34.8 (+16.9)	82.8

#### Failure cases



# Q & A

구현 코드 링크: <a href="https://junyanz.github.io/CycleGAN/">https://junyanz.github.io/CycleGAN/</a> (Pytorch , Torch )